



"Predicción de gestión del transporte público"

Asignatura: Big Data

Sección: 006D

Integrantes: Benjamin Pumarino, Elias Sanchez, Felipe Villanueva

Docente: Matias Rojas

Fecha: 31 de marzo de 2026

Introducción

En el informe se analiza la tecnologías Big Data para la predicción de congestión en el sistema de transporte público en la RED Santiago. debido al crecimiento de la población ocupando el transporte público. utilizando datos abiertos de posicionamiento GPS en tiempo real y evaluaremos la arquitectura de procesamiento capaz de transformar flujos masivos de datos en información de valor para tomar buenas decisiones y cómo se aplican las cuatro v de big data en el caso .

Descripción del Caso

La congestión de vehículos impredecible en Santiago actualmente hace que la gente tenga retrasos en la frecuencia de vehículos públicos (buses). afectando la vida de las personas como por ejemplo en los retrasos al trabajo o clases para la gente que no tiene su propio vehículo y solo se movilizan a través de los vehículos públicos y la eficiencia operativa del sistema.

Organización/Industria: Industria del Transporte Público Metropolitano (RED Santiago).

Fuentes de Datos: Se utilizarán datos del Directorio de Transporte Público Metropolitano (DTPM) como fuente principal, complementados con datos de afluencia de Metro de Santiago, condiciones climáticas de Open Weather API y eventos urbanos de datos.gob.cl.

Necesidad del Negocio: Optimizar la asignación de flota, predecir tiempos de llegada con mayor exactitud y reducir los "cuellos de botella" mediante análisis predictivos

Objetivos Técnicos

Objetivo General Técnico

Diseñar una solución Big Data en Arquitectura Lambda capaz de procesar y analizar datos de transporte público en tiempo real y batch para la generación de métricas de congestión

Objetivos Específicos

- Implementar una ingesta de datos en streaming mediante GTFS Realtime
- Almacenar datos históricos de movilidad para el entrenamiento de modelos predictivos
- Procesar flujos de datos GPS cada pocos segundos para detectar anomalías de velocidad
- Integrar fuentes de datos heterogéneos (clima y eventos) para enriquecer el análisis

Justificación: ¿Por qué es Big Data?

La gestión de RED Santiago cumple con las dimensiones del Big Data debido a la naturaleza de sus sensores GPS y la complejidad de la ciudad.

V	Aplicación en el proyecto
Volumen	Procesamiento de millones de registros GPS generados diariamente por la flota de buses
Velocidad	Los datos de posición (latitud/Longitud) se actualizan cada pocos segundos, requiriendo procesamiento inmediato
Variedad	Combinación de datos estructurados (GTFS), semiestructurados (JSON de APIs CLIMÁTICAS) Y ge espaciales
Veracidad	Manejo de inconsistencias en la señal GPS, datos incompletos o retrasos en la transmisión de red
Valor	Transformación de coordenadas crudas en predicciones de congestión que mejoran la experiencia del usuario

La siguiente tabla desglosa cómo el proyecto cumple con las cinco dimensiones fundamentales del Big Data: Volumen, Velocidad, Variedad, Veracidad y Valor. En ella se puede ver la naturaleza masiva y rápida de los datos generados por los sensores GPS de la flota de buses, se integra de distintas fuentes de información, los desafíos asociados a la calidad de la señal y, finalmente, cómo todo este procesamiento se transforma en predicciones útiles para los usuarios.

Propuesta de Arquitectura y Herramientas

Se ha seleccionado una arquitectura Lambda para permitir el análisis histórico profundo y la reacción inmediata ante incidentes.

Capas de la arquitectura

- **Batch Layer:** Almacenamiento el historial de recorridos y clima para identificar patrones de tráfico a largo plazo
- **Speed Layer:** Procesa el flujo de datos GPS en tiempo real para detectar buses detenidos o tramos con la baja velocidad instantánea
- **Serving Layer:** Expone los resultados procesados tanto de la capa batch como de la speed para consultas rápidas de los dashboards

Herramientas

Capa	Herramienta	Justificación
Ingesta	Google Cloud Pub/Sub	Servicio administrado que reemplaza a Kafka para la ingesta de flujos GPS de alta velocidad en tiempo real.
Batch	Google Cloud Dataproc	Permite ejecutar clústeres de Spark de forma efímera para el procesamiento distribuido de datos históricos de movilidad.
Storage	Cloud Storage (GCS)	Sistema de almacenamiento de objetos altamente escalable para guardar años de historial de recorridos y clima.
Serving	BigQuery	Almacén de datos analíticos para consultas rápidas de congestión y análisis de "cuellos de botella".
Visualización	Power BI	Facilidad para crear mapas de calor de congestión y dashboard para operadores

Con base en la Arquitectura Lambda elegida para analizar tanto el historial profundo como la reacción inmediata a incidentes, la siguiente tabla detalla las herramientas tecnológicas seleccionadas para cada capa del flujo de datos. Se justifica la adopción de servicios administrados y escalables (principalmente del ecosistema de Google Cloud, junto con Power BI) para abarcar de manera eficiente las fases de ingesta, procesamiento batch, almacenamiento masivo, serving de datos y visualización para los operadores.

Herramientas NO adecuadas

Herramienta	Por qué NO
Excel	No tiene la capacidad de escala para procesar millones de registros generados diariamente por la flota de buses.
Cloud SQL (MySQL)	Aunque es un servicio de nube, no está diseñado para el procesamiento masivo de streaming ni para analítica de Big Data a gran escala.

Para contrastar la robustez de la arquitectura propuesta y fundamentar la necesidad de usar tecnologías especializadas en Big Data, la siguiente tabla expone ejemplos de herramientas tradicionales y explica por qué han sido descartadas para este proyecto. Como se detalla a continuación, soluciones convencionales como hojas de cálculo o bases de datos relacionales estándar carecen de la escalabilidad y las capacidades de streaming necesarias para soportar el flujo masivo de información del transporte metropolitano.

Propuesta de Gobierno de Datos

Para garantizar que la información sea confiable y segura, se establecen las siguientes prácticas:

Práctica	Aplicación
Calidad de datos	Filtros de validación para descartar coordenadas GPS fuera del rango geográfico de Santiago
Privacidad	Animación de los ID de conductores y datos que puedan identificar comportamiento individuales
Metadata	Implementación de un catálogo para documentar las versiones de las rutas (GTFS) y esquemas de datos

Con el objetivo de garantizar que la información analizada sea confiable, segura y estructurada, es imperativo aplicar normas estrictas de manejo de información. La siguiente tabla describe tres prácticas esenciales de Gobierno de Datos implementadas en este proyecto. Se especifican los controles aplicados para mantener la calidad de las coordenadas espaciales, proteger la privacidad mediante la anonimización de identificadores y mantener un orden claro a través de metadatos de las rutas.

Roles:

- **Data Owner:** Responsable del dato desde la perspectiva del negocio. Define políticas de uso, acceso y seguridad de la información, asegurando que los datos se utilicen correctamente y cumplan normas organizacionales y legales.
- **Data Steward:** Encargado de mantener la correcta gestión de los datos. aplica reglas de validación, controla inconsistencias y administra para garantizar información confiable.
- **Data Engineer:** Responsable técnico del manejo de datos. Diseña e implementa pipelines, almacenamiento y procesos de transformación que permiten procesar y asegurar los datos dentro de la arquitectura Big Data.

Asociación a Arquitectura de Referencia

Nuestra solución implementa los pilares fundamentales de la Arquitectura Lambda:

Componentes presentes:

Poseen una división clara entre procesamiento de flujo (Speed) para emergencias y procesamiento de lotes (Batch) para estadísticas mensuales.

Componentes que podrían faltar

No se incluyen inicialmente un Sistema de Alertas inteligentes (Notificaciones push automáticas a usuarios) ni un Data Catalog Automatizado

Componentes que NO son necesarios (justificar)

Un sistema de sensores IoT propio no es requerido, ya que se aprovecha la infraestructura GPS ya Instalada en los buses por el DTPM

Conclusión de la idea de proyecto:

El presente Proyecto demuestra que la aplicación de tecnologías Big Data a la gestión del transporte público de RED Santiago representa una solución viable y necesaria frente a los desafíos de congestión que afectan diariamente a miles de usuarios. a través de una arquitectura lambda, es posible combinar el procesamiento en tiempo real de datos GPS con el análisis histórico de patrones de movilidad, permitiendo anticipar cuellos de botella y optimizar la distribución de la flota de una manera eficiente para el caso.

La integración de herramientas como Apache Kafka, Apache Spark y Elasticsearch, junto con fuentes de datos heterogéneas como el clima y eventos urbanos (celebraciones /feriados /etc), valida el cumplimiento de las cinco V del Big Data en este contexto. Asimismo, la propuesta de gobierno de datos asegura que la información procesada sea confiable, segura y trazable , aspectos fundamentales para la toma de decisiones en un sistema crítico de movilidad urbana.

En definitiva, esta solución no solo mejora la experiencia del usuario al reducir tiempos de espera e incertidumbre , sino también eleva la eficiencia operativa del sistema, sentando las para una gestión de transporte público más inteligente y adaptable en una ciudad en constante crecimiento como Santiago.